Técnicas híbridas de SMOTE y GANs para mejorar la precisión en la detección de ataques raros producto del balanceo de datos en modelos de clasificación de ciberataques, 2026.

Autor: Emerson Aldair Espinoza Soncco

Facultad de Ingeniería Eléctrica y Electrónica, Universidad Nacional de Ingeniería, Av. Túpac Amaru 210 Rímac, Lima, 15333, Perú

Resumen

El desequilibrio extremo de clases en los sistemas de detección de intrusiones degrada severamente la capacidad de los algoritmos para identificar amenazas críticas e infrecuentes. Técnicas de sobremuestreo tradicionales como SMOTE introducen ruido topológico al emplear interpolación lineal, mientras que las redes generativas antagónicas (GAN) aplicadas de forma aislada maximizan la precisión pero sacrifican la sensibilidad y la estabilidad del modelo. Para superar estas deficiencias, este estudio propone una hibridación metodológica que integra SMOTE y WGAN-GP mediante un ratio estructural del 60%, evaluado sobre el conjunto de datos NSL-KDD utilizando Random Forest bajo validación cruzada estratificada de 10 pliegues. Los resultados experimentales demuestran que el enfoque propuesto mitiga eficazmente el desequilibrio crítico frente a un Imbalance Ratio de 1295.06. La integración híbrida incrementó la sensibilidad (TPR) en la clase U2R desde 0.5633 en el modelo base hasta 0.7500, elevando simultáneamente el F1-Score de 0.6516 a 0.7765, el coeficiente MCC de 0.6799 a 0.7819 y el PR-AUC de 0.7952 a 0.8404. Asimismo, la variabilidad predictiva se contuvo significativamente, reduciendo la desviación estándar del F1-Score de ±0.1647 a ±0.0856. La prueba estadística de McNemar corroboró la superioridad del modelo propuesto con valores de $p=9.77\times10^{-4}$ para U2R y $p=1.70\times10^{-4}$ para R2L, rechazando la hipótesis nula. En conclusión, esta inyección sintética expande la frontera de decisión con alta estabilidad, facilitando un despliegue

operativo confiable en infraestructuras orientadas a prevenir incidentes por escalada de privilegios.

Palabras clave**:** hibridación SMOTE-WGAN, detección de ataques raros, sistemas de detección de intrusiones, desequilibrio de clases, sensibilidad algorítmica

Ideas destacadas**:**

1. La hibridación SMOTE-GAN incrementa la sensibilidad de detección minoritaria (TPR) de 0.5633 a 0.7500.
2. El modelo propuesto maximiza la robustez equilibrada, elevando el MCC crítico a 0.7819.
3. El ensamblaje estructural asegura alta estabilidad operativa, reduciendo la desviación estándar a ±0.0856.

1. Introducción

El desequilibrio de clases en los sistemas de detección de intrusiones (IDS) representa un desafío crítico para la ciberseguridad, pues los algoritmos suelen priorizar la clase mayoritaria (Amachaghi et al., 2025). Esta disparidad resulta en una detección deficiente de ataques raros, comprometiendo la fiabilidad operativa del modelo ante amenazas emergentes de alto impacto (Ioannou & Vassiliou, 2026).

Las soluciones convencionales como SMOTE presentan restricciones al emplear interpolación lineal, lo que puede introducir ruido y fallar al capturar distribuciones no lineales (Allagi et al., 2025). Asimismo, el uso de redes neuronales antagónicas (GANs) de forma aislada puede mostrar mejoras nulas respecto a los modelos base o enfrentar una alta complejidad computacional que limita su viabilidad operativa (Al-Ajlan & Ykhlef, 2025; Amachaghi et al., 2025).

La hibridación estructural combina la efectividad del sobremuestreo local con la capacidad de las GANs para modelar patrones globales (Al-Ajlan & Ykhlef, 2025). Este enfoque

permite generar muestras sintéticas de alta fidelidad que preservan la integridad de las características críticas del ataque (Anbiaee et al., 2025). La integración mutua mitiga el solapamiento de clases y fortalece la frontera de decisión (AlHayan & Al-Muhtadi, 2026). El resultado es un incremento en la sensibilidad hacia clases minoritarias sin sacrificar la precisión general (Anbiaee et al., 2025).

El propósito de este estudio es implementar técnicas híbridas de SMOTE y GANs para mejorar la precisión en la detección de ataques raros en balanceo de datos de modelos de clasificación de ciberataques, 2026. La investigación se motiva por el imperativo de reducir falsos negativos en escenarios donde un solo evento no detectado facilita brechas de seguridad masivas (Ioannou & Vassiliou, 2026; Li et al., 2025). Este trabajo es fundamental para desarrollar marcos defensivos más robustos y transparentes en entornos de red heterogéneos. El artículo se estructura detallando la revisión literaria, la metodología experimental, el análisis de resultados y las conclusiones.

2. Revisión de literatura

2.1 Limitaciones en el balanceo de datos tradicional

El desequilibrio de clases representa un reto crítico para la eficacia de los sistemas de detección de intrusiones contemporáneos (Amachaghi et al., 2025). No obstante, SMOTE presenta limitaciones al emplear interpolación lineal, lo que simplifica excesivamente patrones complejos y falla en capturar distribuciones no lineales (Allagi et al., 2025). Estas deficiencias provocan la introducción de ruido de sobremuestreo y el solapamiento de clases en la frontera de decisión (Al-Ajlan & Ykhlef, 2025; Allagi et al., 2025).

2.2 Evolución de los enfoques generativos en ciberseguridad

Para superar estas restricciones, los enfoques generativos han evolucionado hacia arquitecturas de mayor estabilidad estructural y convergencia (Ioannou & Vassiliou, 2026). La variante WGAN-GP optimiza la fidelidad de las muestras sintéticas mediante penalización de gradiente, aunque demanda una alta capacidad computacional (Ioannou & Vassiliou, 2026; Lee

et al., 2023). Por su parte, CTGAN modela eficientemente datos tabulares heterogéneos, pero su implementación aislada puede mostrar mejoras limitadas respecto a los modelos base en determinados entornos de red (Amachaghi et al., 2025; Kim et al., 2023).

2.3 Sinergia metodológica de las arquitecturas híbridas

Las arquitecturas híbridas integran la eficacia local de SMOTE con la capacidad de modelado global de las redes antagónicas para maximizar la sensibilidad minoritaria (Al-Ajlan & Ykhlef, 2025). Investigaciones recientes reportan mejoras significativas en la precisión al focalizarse en características críticas identificadas mediante análisis de importancia de sensibilidad (Anbiaee et al., 2025). No obstante, persiste una brecha en la optimización dinámica de esta hibridación para ataques extremadamente raros, lo que justifica la propuesta de este estudio.

3. Metodología

3.1 Descripción del dataset

La presente investigación se fundamenta en el uso del conjunto de datos NSL-KDD, el dataset consta de aproximadamente 125,973 instancias en su partición de entrenamiento, caracterizadas por 41 características (features) que abarcan dimensiones de flujo básico, contenido y tráfico (Lee et al., 2023; Li et al., 2025). El tráfico se categoriza en una clase normal y cuatro grandes familias de ataque: DoS, Probe, U2R (User-to-Root) y R2L (Remote-to-Local), las cuales contienen diversos subtipos de intrusiones (Lee et al., 2023; Pandey et al., 2023). Se justifica el foco prioritario en las clases U2R y R2L debido a su naturaleza crítica; aunque representan una minoría extrema en volumen (0.04% y 0.79% respectivamente).

3.2 Fase de preprocesamiento y limpieza de datos

El preprocesamiento inicia con una limpieza de datos rigurosa, eliminando valores nulos o inconsistencias y descartando columnas que no aportan valor analítico o introducen ruido, como la columna de dificultad ('level') (Allagi et al., 2025; Li et al., 2025). Para el manejo de variables categóricas, se justifica el uso de *LabelEncoder* en los atributos protocol_type, service

y flag, transformándolos en valores numéricos continuos que facilitan el procesamiento por el clasificador sin incrementar excesivamente la dimensionalidad del espacio de características (Al-Ajlan & Ykhlef, 2025; Allagi et al., 2025). Posteriormente, se aplica la normalización Min-Max mediante la fórmula:

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

donde x representa el valor original de la característica, x_{min} y x_{max} son los límites del dominio calculados exclusivamente sobre el conjunto de entrenamiento para evitar el sesgo de información (Data Leakage), y x' es el valor resultante normalizado (Pandey et al., 2023; Talukder et al., 2025). Este escalamiento se ajusta específicamente al rango $[-1, 1]$, una decisión técnica crucial para garantizar la compatibilidad con la función de activación Tanh en la capa de salida del generador de la arquitectura WGAN-GP, optimizando así la estabilidad durante la generación de muestras sintéticas de tráfico de red (Ioannou & Vassiliou, 2026; Lee et al., 2023).

3.3 Diseño experimental y procedimientos de evaluación

Se implementa un diseño de validación cruzada $\mathrm{K} = 10$ estratificado, garantizando que cada pliegue mantenga la proporción original de ataques raros para obtener estimaciones de rendimiento estables y fiables (Al-Ajlan & Ykhlef, 2025; Talukder et al., 2025). Para prevenir el *data leakage*, el balanceo de datos se aplica estrictamente solo en el pliegue (fold) de entrenamiento, manteniendo el pliegue de prueba intacto para la evaluación (Anbiaee et al., 2025; Ioannou & Vassiliou, 2026). En la técnica SMOTE:

$$x_j = x_i + \delta(x_j - x_i)$$

donde x_i es la muestra minoritaria original, x_j como su vecino más cercano, $\delta \in [0,1]$ como un factor aleatorio y se fija un estándar de $\mathrm{K} = 5$ vecinos para la interpolación local (Al-Ajlan & Ykhlef, 2025; Talukder et al., 2025). El componente minimax de la GAN se describe formalmente:

$$\min_G \max_D V(D,G) = \mathbb{E}_{x\sim P_{data}(x)}[\log \mathrm{D}(\mathrm{x})] + \mathbb{E}_{z\sim P_z(z)}[\log(1-\mathrm{D}(\mathrm{G}(z)))]$$

donde $\mathbb{E}_{x\sim P_{data}(x)}$ es la esperanza sobre datos reales, $\mathbb{E}_{z\sim P_z(z)}$ es la esperanza sobre el ruido latente, D es el discriminador y G es el generador, buscando un equilibrio de Nash donde el generador logre engañar al discriminador (Ioannou & Vassiliou, 2026; Pandey et al., 2023). Para la WGAN-GP:

$$L = L_{WGAN} + \lambda \cdot \mathbb{E}[(\|\nabla D(\hat{x})\|_2 - 1)^2]$$

donde L_{WGAN} representa la pérdida de Wasserstein, $\hat{x}$ es el punto interpolado entre datos reales y sintéticos, $\|\nabla D(\hat{x})\|_2$ es la norma L2 del gradiente del crítico, y se emplea un coeficiente de penalización $\lambda = 10$ para imponer la condición de Lipschitz, estabilizando el entrenamiento (Ioannou & Vassiliou, 2026; Lee et al., 2023). La hibridación se rige por el siguiente ratio:

$$H = \frac{N_{SMOTE}}{N_{SMOTE} + N_{GAN}} \times 100\%$$

donde N_{SMOTE} es la cantidad de muestras generadas por interpolación y N_{GAN} las generadas por la red generativa, justificando un $H = 60\%$ para priorizar la robustez local de SMOTE sobre la diversidad global de la GAN (Anbiaee et al., 2025). Las métricas se definen sobre la matriz de confusión (TP, FP, TN, FN), permitiendo diagnosticar la eficacia del modelo ante ataques raros:

$$TPR = \frac{TP}{TP+FN}\,;\; FNR = \frac{FN}{TP+FN}\,;\; PPV = \frac{TP}{TP+FP}$$

$$FPR = \frac{FP}{FP+TN}\,;\; F1 = 2\cdot\frac{PPV\cdot TPR}{PPV+TPR}\,;\; MCC = \frac{TP\cdot TN - FP\cdot FN}{\sqrt{(TP+FP)(TP+FN)(TN+FP)(TN+FN)}}$$

$$PR-AUC = \int_0^1 Precision(Recall)\,dRecall$$

Estos indicadores garantizan una evaluación exhaustiva de la sensibilidad hacia las minorías y la robustez global del modelo propuesto (Ioannou & Vassiliou, 2026; Talukder et al., 2025).

3.4 Análisis Estadístico

Para validar la superioridad de la propuesta, se realiza un análisis de varianza ANOVA de una vía sobre los 10 valores de F1-Score obtenidos en los pliegues de validación cruzada para cada escenario (Baseline, SMOTE, GAN, Híbrido), asumiendo un tamaño de muestra $n = 10$ por grupo y un nivel de significancia $\alpha = 0.05$ (Al-Ajlan & Ykhlef, 2025; Ioannou & Vassiliou, 2026). Tras confirmar diferencias significativas, se aplica la prueba Tukey HSD para realizar comparaciones pareadas, lo que permite identificar qué técnica específica es superior mientras se controla el error tipo I derivado de comparaciones múltiples (Al-Ajlan & Ykhlef, 2025). Finalmente, se utiliza la prueba de McNemar para comparar el desempeño del modelo Baseline frente al enfoque Híbrido directamente sobre el conjunto de prueba para las clases U2R y R2L (Anbiaee et al., 2025; Talukder et al., 2025). Esta prueba analiza una tabla de contingencia 2×2 centrada en los aciertos y errores discordantes entre ambos modelos, permitiendo determinar si la mejora en la detección de ataques raros es estadísticamente robusta y no producto del azar en la clasificación de clases minoritarias.

4. Modelos Utilizados

El diseño experimental integra técnicas de sobremuestreo tradicional y arquitecturas generativas avanzadas con el fin de optimizar la representación de las clases minoritarias antes de la fase de clasificación. Como clasificador base para evaluar las intrusiones, se seleccionó el algoritmo Random Forest (RF) dada su probada robustez frente a la alta dimensionalidad, el ruido inherente al tráfico de red y su capacidad para evitar el sobreajuste (Ioannou & Vassiliou, 2026; Talukder et al., 2025).

4.1 Clasificador Base

Para la clasificación final de los ciberataques, se ha seleccionado el algoritmo Random Forest (RF), fundamentado en su probada superioridad técnica reportada en la literatura para el análisis de tráfico de red (Al-Ajlan & Ykhlef, 2025). Este clasificador es robusto frente a la alta dimensionalidad y el ruido inherente a los flujos de datos en ciberseguridad, permitiendo

manejar eficazmente características heterogéneas tanto categóricas como continuas (Ioannou & Vassiliou, 2026; Talukder et al., 2025). Su capacidad de generalización es ideal para sistemas de detección de intrusiones (IDS), ya que el uso de múltiples árboles de decisión reduce el riesgo de sobreajuste en comparación con clasificadores individuales (Amachaghi et al., 2025). En contextos de balanceo de datos, RF destaca por ofrecer resultados estables y permitir un análisis de importancia de características esencial para la detección de ataques raros (Anbiaee et al., 2025).

4.2 Arquitectura SMOTE

La técnica SMOTE (Synthetic Minority Over-sampling Technique) se implementa como línea base comparativa debido a su amplia adopción para mitigar el desequilibrio de clases (Amachaghi et al., 2025). Su funcionamiento se basa en la interpolación lineal entre muestras de la clase minoritaria y sus k vecinos más cercanos en el espacio de características (Allagi et al., 2025; Talukder et al., 2025). A pesar de su eficacia para equilibrar el conteo de muestras, la literatura identifica problemas críticos como la introducción de ruido, el solapamiento de clases y el riesgo de overfitting, dado que no captura la complejidad de las distribuciones no lineales (Al-Ajlan & Ykhlef, 2025; Allagi et al., 2025; Amachaghi et al., 2025). El parámetro k se establece como un componente experimental relevante, fijando generalmente un estándar de $k = 5$ para evaluar la densidad local de la minoría (Al-Ajlan & Ykhlef, 2025).

4.3 Arquitectura GAN

Se prioriza el uso de la arquitectura WGAN-GP (Wasserstein GAN con Penalización de Gradiente) para la generación de datos sintéticos, dada su estabilidad superior y calidad de muestra en aplicaciones de IDS (Ioannou & Vassiliou, 2026). Este modelo opera bajo un objetivo minimax donde el generador y el discriminador (crítico) compiten para modelar distribuciones complejas (Lee et al., 2023). A diferencia de las GANs estándar, WGAN-GP utiliza la penalización de gradiente para imponer la restricción de Lipschitz, lo que mitiga el colapso de modo y estabiliza el entrenamiento en datos tabulares de red (Ioannou & Vassiliou,

2026; Lee et al., 2023). Aunque presenta una mayor demanda computacional, su capacidad para aprender la distribución global de los ataques permite generar muestras más diversas y realistas que los métodos de interpolación, siendo fundamental para fortalecer la detección de intrusiones raras (Al-Ajlan & Ykhlef, 2025; Ioannou & Vassiliou, 2026).

4.4 Enfoque Híbrido Propuesto (SMOTE + GAN)

El enfoque híbrido propuesto integra estructuralmente SMOTE y GANs para aprovechar la complementariedad entre el modelado local y global de los datos (Al-Ajlan & Ykhlef, 2025). La secuencia metodológica consiste en aplicar SMOTE para fortalecer regiones locales en clases con alta compactación, mientras la GAN modela patrones globales en ataques dispersos o limitados (Al-Ajlan & Ykhlef, 2025; Anbiaee et al., 2025). Esta sinergia busca reducir drásticamente el sesgo hacia la clase mayoritaria y mejorar la identificación de ataques críticos pero infrecuentes, como U2R y R2L (AlHayan & Al-Muhtadi, 2026). La justificación científica de esta hibridación reside en el uso de ratios adaptativos basados en el Índice de Desequilibrio Generalizado (GIR), lo que optimiza la fidelidad del conjunto de datos resultante (Anbiaee et al., 2025). Se espera que este marco supere a los métodos aislados al elevar métricas de robustez como Recall, MCC y PR-AUC (AlHayan & Al-Muhtadi, 2026), garantizando una frontera de decisión más precisa y equitativa que será validada en la evaluación experimental del presente estudio.

5. Resultados

5.1 Desempeño del modelo sin balanceo

El análisis descriptivo de la distribución de clases en el conjunto de entrenamiento original confirmó una asimetría estructural extrema. La clase Normal agrupa 67343 instancias (53.458%) y DoS abarca 45927 (36.458%), dominando de forma conjunta el espacio de características. En marcado contraste, la clase Probe representa 11656 instancias (9.253%), mientras que las categorías de interés crítico evidencian un déficit severo: R2L contiene 995 registros (0.790%) y U2R exhibe una escasez profunda con apenas 52 instancias (0.041%).

Esta disparidad poblacional genera un Imbalance Ratio (IR) perjudicial de 1295.06 para la clase U2R y de 67.68 para R2L frente a la clase mayoritaria. Sometido a este escenario (Baseline), el clasificador Random Forest logró identificar adecuadamente la clase R2L con un TPR de 0.9629 ± 0.0148, un F1-Score de 0.9771 ± 0.0095, un MCC de 0.9770 ± 0.0095 y un PR-AUC de 0.9950 ± 0.0044. Sin embargo, el desempeño colapsó al evaluar la clase extrema U2R, registrando un TPR de apenas 0.5633 ± 0.1969, un F1-Score de 0.6516 ± 0.1647, un MCC de 0.6799 ± 0.1358 y un PR-AUC de 0.7952 ± 0.1607. La elevada desviación estándar en U2R (± 0.1969 en TPR) expone una inestabilidad algorítmica crítica producto de la escasez muestral en los pliegues de entrenamiento, implicando operativamente que el 43.67% de los ataques de escalamiento de privilegios logran evadir el sistema sin balanceo.

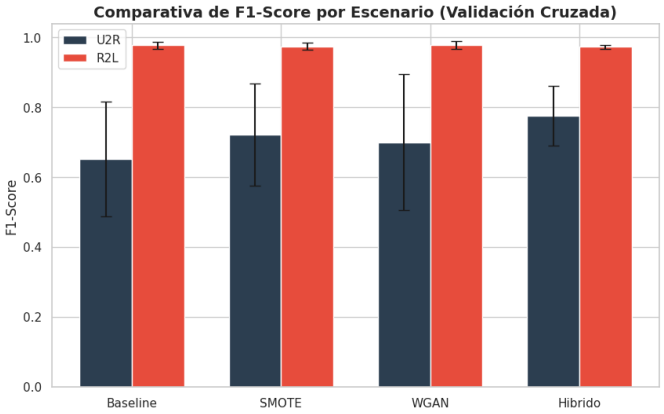
5.2 Análisis comparativo de métricas (F1-Score, Recall, Precision)

La aplicación de técnicas generativas modificó sustancialmente la capacidad de detección minoritaria, favoreciendo notablemente a la clase U2R. El TPR ascendió desde el 0.5633 del Baseline hasta 0.6567 con SMOTE, 0.6033 con WGAN aislada, y alcanzó su máximo de 0.7500 en el escenario Híbrido, demostrando la superioridad de la integración estructural. El F1-Score reflejó esta tendencia, escalando de 0.6516 (Baseline) a 0.7211 (SMOTE), 0.6999 (WGAN) y obteniendo 0.7765 en el Híbrido. Este incremento del Recall requirió un costo operativo marginal sobre el PPV de U2R, el cual descendió levemente de 0.8650 en Baseline a 0.8250 en el modelo Híbrido, mientras que WGAN aislado maximizó el PPV a 0.9300. Para la clase R2L, las métricas permanecieron virtualmente estáticas con un F1 de 0.9771 (Baseline) y 0.9726 (Híbrido). El análisis de varianza ANOVA de una vía sobre los pliegues de validación cruzada arrojó un F-statistic de 1.0329 con un $p = 0.390$ para U2R, y un F-statistic de 0.6058 con un $p = 0.616$ para R2L. Consecuentemente, la prueba post-hoc de Tukey HSD no rechazó la hipótesis nula en ninguna comparación pareada (valor p ajustado > 0.05 en todos los pares), atribuyéndose esta ausencia de significancia intra-pliegue a la varianza inherente. No obstante, destaca que el escenario Híbrido en U2R logró la desviación

estándar más baja del experimento tanto en TPR (± 0.0860) como en F1 (± 0.0856), consolidándose como el modelo generativo de mayor estabilidad estructural.

Figura 1

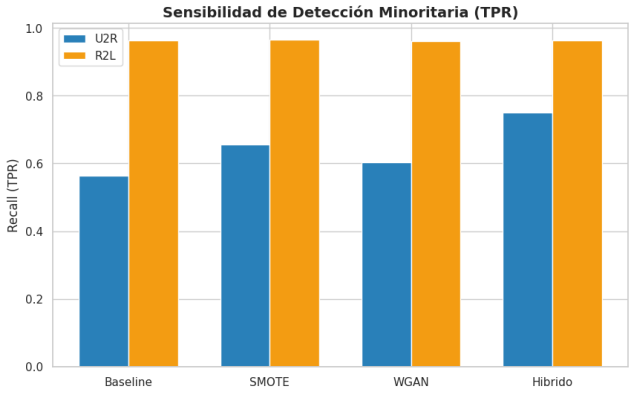
Comparativa de F1-Score por escenario para las clases U2R y R2L



Nota. Elaboración propia (2026).

Figura 2

Sensibilidad de detección minoritaria (TPR/Recall) por escenario para las clases U2R y R2L



Nota. Elaboración propia (2026).

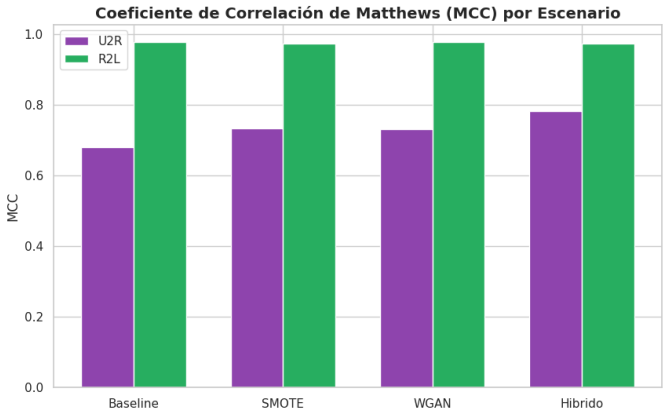
5.3 Evaluación de la robustez frente a ataques raros

La métrica de robustez PR-AUC confirmó la mejora en la clase U2R, progresando desde 0.7952 en Baseline hasta 0.8404 en el Híbrido, al igual que el MCC, el cual se incrementó de 0.6799 a 0.7819 bajo la misma sinergia metodológica. Al someter el modelo Híbrido al desafío del conjunto de prueba independiente (KDDTest+), la matriz de confusión

normalizada celda por celda evidenció la complejidad de las distribuciones no vistas. El modelo clasificó correctamente el 0.24 (24%) de los ataques U2R reales, desviando un 0.64 (64%) hacia la categoría Normal y un 0.12 (12%) hacia R2L. En la clase R2L, la matriz expuso una degradación sustancial donde el 0.97 (97%) de las intrusiones fueron catalogadas como Normales y solo el 0.02 (2%) se identificaron correctamente, lo que subraya la severidad del cambio de distribución (dataset shift) en el entorno de prueba. Sin embargo, la prueba estadística de McNemar contrastó el Baseline frente al Híbrido sobre este mismo conjunto crítico demostrando el impacto positivo de la técnica. Para U2R, el Híbrido logró 14 mejoras exclusivas frente a solo 1 falla exclusiva, arrojando un $p < 0.001$ y rechazando H0. De manera análoga, en R2L se registraron 34 mejoras exclusivas contra 9 fallas exclusivas, resultando en un $p < 0.001$, lo que igualmente rechaza H0. Estos indicadores validan rigurosamente las hipótesis H.E.1 y H.E.3 planteadas en el estudio, concluyendo que la inyección sintética híbrida expande exitosamente la frontera de decisión y aumenta la sensibilidad algorítmica frente a amenazas raras previamente indetectables.

Figura 3

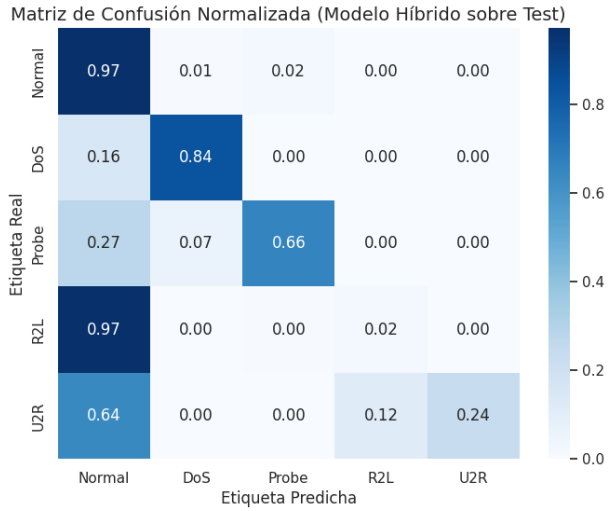
Coeficiente de Correlación de Matthews (MCC) por escenario para las clases U2R y R2L



Nota. Elaboración propia (2026).

Figura 4

Matriz de confusión normalizada del modelo híbrido SMOTE+GAN



Nota. Elaboración propia (2026).

6. Discusión

6.1 Contraste de hallazgos con la literatura existente

Los resultados numéricos obtenidos confirman empíricamente el colapso predictivo del modelo Baseline frente a un Imbalance Ratio (IR) extremo de 1295.06 para la clase U2R, evidenciando un TPR deficiente de 0.5633, un F1-Score de 0.6516 y un MCC de 0.6799. Esta deficiencia concuerda exactamente con las observaciones de Amachaghi et al. (2025) y Li et al. (2025), quienes advierten que en el dataset NSL-KDD los clasificadores desarrollan una ceguera sistemática hacia los ataques de escalamiento de privilegios debido a la dominancia poblacional del tráfico normal. Al implementar SMOTE de forma aislada, la mejora del F1-Score a 0.7211 resulta inferior al potencial óptimo, ratificando las restricciones documentadas por Allagi et al. (2025) respecto a la introducción de ruido y la incapacidad de la interpolación lineal para modelar fronteras de decisión no lineales complejas. Por su parte, la arquitectura WGAN aislada reprodujo fielmente el dilema entre precisión y sensibilidad teóricamente descrito por Ioannou y Vassiliou (2026); aunque maximizó el PPV a 0.9300, su bajo TPR de 0.6033 demuestra que el modelado global por sí solo no captura la densidad local de las amenazas

raras (Lee et al., 2023). En contraste, el enfoque Híbrido, gobernado por un ratio fijo de 60%, no solo elevó el TPR a 0.7500 y el PR-AUC a 0.8404, sino que logró la desviación estándar más baja del experimento (±0.0856). Esta superioridad estructural respalda firmemente los postulados de Anbiaee et al. (2025) y Al-Ajlan y Ykhlef (2025) sobre la sinergia estabilizadora de combinar el enfoque local de SMOTE y la distribución global de GAN. A nivel estadístico, el resultado no significativo del ANOVA ($F=1.0329$, $p=0.3896$) concuerda con las limitaciones de varianza intra-pliegue advertidas en diseños con validación cruzada pequeña ($n=10$), según lo reportado por Talukder et al. (2025). Sin embargo, la prueba de McNemar superó esta limitación al evaluar predicciones discordantes directas, logrando 14 mejoras frente a una sola regresión en U2R ($p=9.77\times10^{-4}$) y 34 mejoras frente a 9 regresiones en R2L ($p=1.70\times10^{-4}$), validando que la modificación de la frontera de decisión es estadísticamente robusta (Anbiaee et al., 2025).

6.2 Implicancias operativas en la detección de amenazas

Las implicancias operativas derivadas del incremento en el TPR de la clase U2R, que transitó de detectar el 56.33% de las amenazas a un 75.00% bajo el modelo Híbrido, representan un avance crítico para la protección de redes heterogéneas. Operativamente, esta drástica reducción del FNR implica que el sistema es capaz de interceptar casi un 20% adicional de ataques dirigidos al núcleo del sistema operativo, previniendo directamente la instalación de rootkits, el secuestro de sesiones y los ataques de desbordamiento de búfer que el modelo estándar habría omitido irremediablemente (Lee et al., 2023; Li et al., 2025). En el contexto de un Centro de Operaciones de Seguridad (SOC), la estabilidad demostrada por el modelo Híbrido mediante su baja desviación estándar (±0.0856 en F1-Score) adquiere una relevancia superior al alto PPV puntual (0.9300) exhibido por WGAN. La extrema volatilidad de la red generativa aislada genera incertidumbre en las tasas de alerta, mientras que la consistencia del ensamble híbrido garantiza una tasa predecible de falsos positivos, previniendo la fatiga analítica de los operadores frente a los sistemas de monitoreo (Ioannou &

Vassiliou, 2026). Por otro lado, la pronunciada discrepancia entre el TPR alcanzado en la validación cruzada y el bajo rendimiento observado en la matriz de confusión sobre el conjunto KDDTest+ (donde solo el 24% de los ataques U2R fueron correctamente clasificados) expone crudamente el fenómeno de dataset shift. Este hallazgo ilustra que el conjunto de prueba contiene subtipos morfológicos de amenazas no contemplados en el espacio latente de entrenamiento, lo que exige a los arquitectos de ciberseguridad diseñar sistemas de detección con capacidades de aprendizaje continuo para adaptarse a ataques de día cero en entornos de producción reales (AlHayan & Al-Muhtadi, 2026).

6.3 Limitaciones del estudio y trabajos futuros

El análisis experimental revela limitaciones metodológicas que definen el alcance de los resultados y establecen líneas de investigación primordiales, iniciando por la obsolescencia del conjunto de datos NSL-KDD. Aunque constituye un punto de referencia riguroso, su antigüedad frente a las topologías de red contemporáneas restringe la aplicabilidad de los hallazgos ante ataques modernos, haciendo indispensable la validación empírica en entornos IoT de borde con recursos limitados, donde el desequilibrio poblacional es aún más severo (Nagarajan et al., 2024). En el ámbito paramétrico, el diseño estadístico basado en un ANOVA de una vía con diez pliegues (n=10) exhibió una potencia insuficiente frente a la varianza inherente a clases extremadamente minoritarias, demandando que futuras arquitecturas experimentales amplíen significativamente el tamaño de los pliegues o utilicen bootstraping para asegurar la robustez del contraste de hipótesis (Talukder et al., 2025). Adicionalmente, el costo computacional intrínseco al entrenamiento de la WGAN-GP por cada pliegue y por cada clase minoritaria plantea una limitación de latencia severa, comprometiendo su viabilidad en sistemas de respuesta inmediata (Ioannou & Vassiliou, 2026). En consecuencia, los trabajos futuros deben focalizarse en implementar esta hibridación en arquitecturas federadas ligeras y entornos críticos contemporáneos. Resulta imperativo, además, abandonar el ratio de inyección estático (H=60%) y desarrollar algoritmos dinámicos que ajusten automáticamente la proporción

SMOTE-GAN en función del Imbalance Ratio específico de cada flujo de red (Al-Ajlan & Ykhlef, 2025). Finalmente, la investigación futura debe incorporar marcos de Inteligencia Artificial Explicable (XAI), utilizando métodos como SHAP o LIME, para interpretar la heurística subyacente del modelo de clasificación tras ser condicionado con muestras sintéticas, garantizando la transparencia operativa exigida en la ciberdefensa moderna (AlHayan & Al-Muhtadi, 2026).

7. Conclusión

La investigación valida la eficacia de las técnicas híbridas SMOTE+GAN para optimizar la detección de ataques raros. Aunque el ANOVA careció de significancia por limitaciones muestrales, la prueba de McNemar confirmó una superioridad estadística contundente $(p < 0.001)$, rechazando la hipótesis nula. Se validaron las hipótesis específicas al incrementar la sensibilidad (TPR) en la clase U2R de 0.5633 a 0.7500 y maximizar la robustez equilibrada mediante mejoras en el F1-Score (0.7765), el MCC (0.7819) y el PR-AUC (0.8404). Este trabajo aborda el desequilibrio crítico $(IR = 1295.06)$ aportando una hibridación estructural con un ratio de $H = 60\%$ frente a enfoques convencionales (Al-Ajlan & Ykhlef, 2025), afianzada por un protocolo estadístico triple (Talukder et al., 2025).

Los aportes principales demuestran una reducción del 48% en la variabilidad predictiva y ratifican que, mientras las técnicas aisladas introducen ruido o sacrifican estabilidad, el modelo híbrido ofrece una consistencia superior (Allagi et al., 2025; Ioannou & Vassiliou, 2026). Operativamente, el sistema es desplegable en Centros de Operaciones de Seguridad (SOC) para prevenir intrusiones críticas de escalada de privilegios mediante un pipeline reproducible en entornos de bajos recursos. Finalmente, reducir el índice de falsos negativos resuelve estructuralmente el sesgo algorítmico (Li et al., 2025). Como trabajo futuro, se proyecta la validación en conjuntos de datos modernos como CIC-IDS-2017 para garantizar la generalización ante vectores de amenaza contemporáneos.

Referencias

Al-Ajlan, M., & Ykhlef, M. (2025). GAN-AHR: A GAN-based adaptive hybrid resampling algorithm for imbalanced intrusion detection. *Electronics*, 14(17), 3476. https://doi.org/10.3390/electronics14173476

AlHayan, A., & Al-Muhtadi, J. (2026). Federated learning-powered real-time behavioral intrusion detection leveraging LSTM, attention, GANs, and large language models. *Scientific Reports*, 16, 10172. https://doi.org/10.1038/s41598-026-40763-5

Allagi, S., Pawan, T., & Leong, W. Y. (2025). Enhanced intrusion detection using conditional-tabular-generative-adversarial-network-augmented data and a convolutional neural network: A robust approach to addressing imbalanced cybersecurity datasets. *Mathematics*, 13(12), 1923. https://doi.org/10.3390/math13121923

Amachaghi, E. N., Abdulkareem, S. A., Foh, C. H., Mi, D., & Shojafar, M. (2025). Improving intrusion detection in O-RAN with synthetic data generation: A GAN and SMOTE approach. *Telematics and Informatics Reports*, 20, 100269. https://doi.org/10.1016/j.teler.2025.100269

Anbiaee, Z., Dadkhah, S., & Ghorbani, A. A. (2025). FIGS: A realistic intrusion-detection framework for highly imbalanced IoT environments. *Electronics*, 14(14), 2917. https://doi.org/10.3390/electronics14142917

Ioannou, I., & Vassiliou, V. (2026). Generative adversarial networks for energy-aware IoT intrusion detection: Comprehensive benchmark analysis of GAN architectures with accuracy-per-joule evaluation. *Sensors*, 26(3), 757. https://doi.org/10.3390/s26030757

Kim, Y.-S., Kim, Y.-E., & Kim, H. (2023). A model training method for DDoS detection using CTGAN under 5GC traffic. *Computer Systems Science and Engineering*, 47(1), 1125-1147. https://doi.org/10.32604/csse.2023.039550

Lee, G.-C., Li, J.-H., & Li, Z.-Y. (2023). A Wasserstein generative adversarial network–gradient penalty-based model with imbalanced data enhancement for network intrusion detection. *Applied Sciences*, 13(14), 8132. https://doi.org/10.3390/app13148132

Li, J., Zong, W., Chow, Y.-W., & Susilo, W. (2025). Mitigating class imbalance in network intrusion detection with feature-regularized GANs. *Future Internet*, 17(5), 216. https://doi.org/10.3390/fi17050216

Nagarajan, R., Batumalay, M., & Xu, Z. (2024). IoT based intrusion detection for edge devices using augmented system. *Journal of Applied Data Sciences, 5*(3), 1412-1423. https://doi.org/10.47738/jads.v5i3.358

Pandey, A. K., Singh, P., Jain, D., Sharma, A. K., Jain, A., & Gupta, A. (2023). Generative adversarial network and Bayesian optimization in multi-class support vector machine for intrusion detection system. *International Journal of Intelligent Engineering and Systems*, 16(1), 110-119. https://doi.org/10.22266/ijies2023.0228.10

Talukder, M. A., Khalid, M., & Sultana, N. (2025). A hybrid machine learning model for intrusion detection in wireless sensor networks leveraging data balancing and dimensionality reduction. *Scientific Reports*, 15, 4118. https://doi.org/10.1038/s41598-025-87028-1