Sistematización del Tema de Investigación

Línea de Investigación:

IA Explicable (XAI) y Ciencia de Datos

Diagnóstico Preliminar:

En el desarrollo de modelos de Machine Learning orientados a la detección de ciberataques, la distribución inherentemente asimétrica de los conjuntos de datos de seguridad representa una limitación estructural crítica. Los datasets de ciberseguridad presentan una marcada disparidad poblacional, donde las muestras de tráfico benigno superan masivamente a los eventos maliciosos y, dentro de estos últimos, los ataques raros constituyen una fracción mínima del total disponible. Esta asimetría obliga a los clasificadores a desarrollar un sesgo sistemático hacia la clase mayoritaria, generando modelos con una exactitud global aparentemente elevada pero con una capacidad real de detección gravemente comprometida frente a amenazas minoritarias. Las técnicas tradicionales de balanceo aplicadas de forma aislada resultan insuficientes para capturar la complejidad distribucional real de los patrones de ataque, limitando la viabilidad de construir modelos equitativos, precisos y generalizables en escenarios de detección de amenazas infrecuentes.

Tema General:

Modelos de clasificación de ciberataques

Temas Particulares:

1. Detección de ataques raros en modelos de clasificación de ciberataques
2. Balanceo de datos en modelos de clasificación de ciberataques
3. Evaluación de rendimiento en modelos de clasificación de ciberataques

Temas Específicos:

1. Baja precisión en la detección de ataques raros producto del balanceo de datos en modelos de clasificación de ciberataques.
2. Baja equidad en la clasificación de ataques raros producto del balanceo de datos en modelos de clasificación de ciberataques.
3. Alto sesgo hacia la clase mayoritaria en el balanceo de datos en modelos de clasificación de ciberataques.

Problema de Estudio:

Baja precisión en la detección de ataques raros producto del balanceo de datos en modelos de clasificación de ciberataques, 2026.

Título Preliminar:

Precisión en la detección de ataques raros producto del balanceo de datos en modelos de clasificación de ciberataques, 2026.

- **Variable dependiente:** Precisión en la detección de ataques raros
- **Objeto de estudio:** Balanceo de datos
- **Alcance espacial:** Modelos de clasificación de ciberataques
- **Alcance temporal:** 2026

Antecedentes Bibliográficos:

1. Anbiaee, Z., Dadkhah, S., & Ghorbani, A. A. (2025). FIGS: A realistic intrusion-detection framework for highly imbalanced IoT environments. *Electronics*, *14*(14). https://doi.org/10.3390/electronics14142917
2. Al-Ajlan, M., & Ykhlef, M. (2025). GAN-AHR: A GAN-based adaptive hybrid resampling algorithm for imbalanced intrusion detection. *Electronics*, *14*(17). https://doi.org/10.3390/electronics14173476
3. AlHayan, A., & Al-Muhtadi, J. (2026). Federated learning-powered real-time behavioral intrusion detection leveraging LSTM, attention, GANs, and large language models. *Scientific Reports*, *16*(1). https://doi.org/10.1038/s41598-026-40763-5
4. Allagi, S., Pawan, T., & Leong, W. Y. (2025). Enhanced intrusion detection using conditional-tabular-generative-adversarial-network-augmented data and a convolutional neural network: A robust approach to addressing imbalanced cybersecurity datasets. *Mathematics*, *13*(12). https://doi.org/10.3390/math13121923
5. Amachaghi, E. N., Abdulkareem, S. A., Foh, C. H., Mi, D., & Shojafar, M. (2025). Improving intrusion detection in O-RAN with synthetic data generation: A GAN and SMOTE approach. *Telematics and Informatics Reports*, *20*. https://doi.org/10.1016/j.teler.2025.100269
6. Ioannou, I., & Vassiliou, V. (2026). Generative adversarial networks for energy-aware IoT intrusion detection: Comprehensive benchmark analysis of GAN architectures with accuracy-per-joule evaluation. *Sensors*, *26*(3). https://doi.org/10.3390/s26030757
7. Kim, Y.-S., Kim, Y.-E., & Kim, H. (2023). A model training method for DDoS detection using CTGAN under 5GC traffic. *Computer Systems Science and Engineering*, *47*(1), 1125–1147. https://doi.org/10.32604/csse.2023.039550
8. Lee, G.-C., Li, J.-H., & Li, Z.-Y. (2023). A Wasserstein generative adversarial network–gradient penalty-based model with imbalanced data enhancement for network intrusion detection. *Applied Sciences*, *13*(14). https://doi.org/10.3390/app13148132
9. Li, J., Zong, W., Chow, Y.-W., & Susilo, W. (2025). Mitigating class imbalance in network intrusion detection with feature-regularized GANs. *Future Internet*, *17*(5). https://doi.org/10.3390/fi17050216
10. Nagarajan, R., Batumalay, M., & Xu, Z. (2024). IoT based intrusion detection for edge devices using augmented system. *Journal of Applied Data Sciences*, *5*(3), 1412–1423. https://doi.org/10.47738/jads.v5i3.358
11. Pandey, A. K., Singh, P., Jain, D., Sharma, A. K., Jain, A., & Gupta, A. (2023). Generative adversarial network and Bayesian optimization in multi-class support vector machine for intrusion detection system. *International Journal of Intelligent Engineering and Systems*, *16*(1), 110–119. https://doi.org/10.22266/ijies2023.0228.10

12. Talukder, M. A., Khalid, M., & Sultana, N. (2025). A hybrid machine learning model for intrusion detection in wireless sensor networks leveraging data balancing and dimensionality reduction. *Scientific Reports*, *15*(1). https://doi.org/10.1038/s41598-025-87028-1

Título Tentativo:

Técnicas híbridas de SMOTE y GANs para mejorar la precisión en la detección de ataques raros producto del balanceo de datos en modelos de clasificación de ciberataques, 2026.

- **Variable independiente:** Técnicas híbridas de SMOTE y GANs
- **Variable dependiente:** Precisión en la detección de ataques raros
- **Objeto de estudio:** Balanceo de datos
- **Alcance espacial:** Modelos de clasificación de ciberataques
- **Alcance temporal:** 2026

MATRIZ DE CONSISTENCIA

Título: Técnicas híbridas de SMOTE y GANs para mejorar la precisión en la detección de ataques raros producto del balanceo de datos en modelos de clasificación de ciberataques, 2026.

LINEA DE INVESTIGACIÓN	PROBLEMA DE ESTUDIO	PROBLEMAS	HIPÓTESIS	OBJETIVOS	VARIABLES Y DIMENSIONES	DISEÑO METODOLÓGICO
IA Explicable (XAI) y Ciencia de Datos **OBJETO DE ESTUDIO** Balanceo de datos	Baja precisión en la detección de ataques raros producto del balanceo de datos en modelos de clasificación de ciberataques, 2026.	**Problema general:** ¿De qué manera las Técnicas híbridas de SMOTE y GANs impactan sobre la Precisión en la detección de ataques raros en Balanceo de datos de Modelos de clasificación de ciberataques, 2026? **Problemas específicos:**	**Hipótesis general:** La implementación de Técnicas híbridas de SMOTE y GANs mejora significativamente la Precisión en la detección de ataques raros en Balanceo de datos de Modelos de clasificación de ciberataques, 2026. **Hipótesis específicas:**	**Objetivo general:** Implementar Técnicas híbridas de SMOTE y GANs para mejorar la Precisión en la detección de ataques raros en Balanceo de datos de Modelos de clasificación de ciberataques, 2026. **Objetivos específicos:**	**Variable independiente:** (Cuantitativo) Técnicas híbridas de SMOTE y GANs **Dimensiones** - **Dimensión 1:** Parámetros de Vecindad Topológica (Componente SMOTE) **Indicador:** Número de vecinos más cercanos (k). - **Dimensión 2:** Estabilidad de Convergencia Antagónica (Componente GAN) **Indicador:** Función de pérdida del Generador y Discriminador. - **Dimensión 3:** Proporción de Hibridación Estructural **Indicador:** Ratio de inyección SMOTE/GAN (%). **Variable dependiente:**	**Enfoque:** Cuantitativo **Tipo de Investigación:** Aplicada **Nivel de Investigación:** Explicativo **Diseño:** Cuasi-experimental, Transversal **Población:** Datasets de ciberseguridad con clases desbalanceadas. **Muestra**: Muestreo no probabilístico intencional. **Técnicas y Herramientas de Recolección de Datos:** **Técnicas**: Simulación computacional repetitiva, validación cruzada y benchmarking de métricas de desempeño. **Herramientas**: - Scripts automatizados en Python utilizando *PyTorch/TensorFlow* (arquitecturas GAN), *imbalanced-learn* (SMOTE) y *scikit-learn*. **Técnicas de Análisis y Procesamiento de Datos:** **Análisis:** -ANOVA de una vía -Prueba Post-hoc Tukey HSD -Prueba de McNemar

		1. ¿De qué manera las Técnicas híbridas de SMOTE y GANs incrementan la Sensibilidad de Detección Minoritaria en Balanceo de datos de Modelos de clasificación de ciberataques, 2026? 2. ¿De qué manera las Técnicas híbridas de SMOTE y GANs optimizan el Valor Predictivo Positivo Minoritario en Balanceo de datos de Modelos de clasificación de ciberataques, 2026? 3. ¿De qué manera las Técnicas híbridas de SMOTE y GANs maximizan la Robustez de Clasificación Equilibrada en Balanceo de datos de Modelos de clasificación de ciberataques, 2026?	H.E. 1: Las Técnicas híbridas de SMOTE y GANs incrementan significativamente la Sensibilidad de Detección Minoritaria en Balanceo de datos de Modelos de clasificación de ciberataques, 2026. H.E. 2: Las Técnicas híbridas de SMOTE y GANs optimizan sustancialmente el Valor Predictivo Positivo Minoritario en Balanceo de datos de Modelos de clasificación de ciberataques, 2026. H.E. 3: Las Técnicas híbridas de SMOTE y GANs maximizan estadísticamente la Robustez de Clasificación Equilibrada en Balanceo de datos de Modelos de clasificación de ciberataques, 2026.	O.E. 1: **Evaluar** cómo las Técnicas híbridas de SMOTE y GANs incrementan la Sensibilidad de Detección Minoritaria en Balanceo de datos de Modelos de clasificación de ciberataques, 2026. O.E. 2: **Determinar** cómo las Técnicas híbridas de SMOTE y GANs optimizan el Valor Predictivo Positivo Minoritario en Balanceo de datos de Modelos de clasificación de ciberataques, 2026. O.E. 3: Comprobar que las Técnicas híbridas de SMOTE y GANs maximizan la Robustez de Clasificación Equilibrada en Balanceo de datos de Modelos de clasificación de ciberataques, 2026.	Precisión en la detección de ataques raros (Cuantitativo) **Dimensiones** - Dimensión 1: Sensibilidad de Detección Minoritaria **Indicador 1.1:** *Tasa de Verdaderos Positivos (TPR/Recall).* **Indicador 1.2:** Tasa de Falsos Negativos (FNR). - Dimensión 2: Valor Predictivo Positivo Minoritario **Indicador 2.1:** Tasa de Falsos Positivos (FPR). **Indicador 2.2:** Proporción de acierto de clase (PPV/Precision). - Dimensión 3: Robustez de Clasificación Equilibrada **Indicador 3.1:** Media armónica Precision-Recall (F1-Score). **Indicador 3.2:** Área bajo la Curva Precisión-Sensibilidad (PR-AUC). **Indicador 3.3**: Coeficiente de Correlación de Matthews (MCC).	